

Analyse univariée des données

Comprendre, décrire, interpréter
et préparer la décision

Note de cours · Formation Data Analyst

Applications sous Excel

Cas fil rouge : Makala Distribution Group (MDG)

De la base de transactions à une lecture statistique rigoureuse et utile au management.
Définitions, indicateurs, interprétations, contrôle qualité et exercices d'application.

Table des matières

Avant-propos	2
1 Du souci du décideur à la question statistique	2
2 Définition et rôle de l'analyse univariée	3
3 Quand utiliser l'analyse univariée ?	4
4 Identifier le type de variable	4
5 Analyser une variable qualitative	5
6 Analyser une variable quantitative	6
7 Moyenne, médiane et mode : choisir le bon centre	6
8 Quartiles et lecture de la position des données	7
9 Dispersion : étendue, écart-type et IQR	8
10 Valeurs atypiques : détecter sans supprimer aveuglément	8
11 Choisir et interpréter les graphiques	9
12 Applications détaillées au cas MDG	10
13 Rentabilité : ce que l'univarié permet de dire	10
14 Du résultat à la décision	11
15 Limites et transition vers l'analyse bivariée	12
16 Fiche méthode et exercices d'application	12
Glossaire essentiel	14
Conclusion générale	14
Annexe pratique : mise en œuvre sous Excel	14

Statut des exemples chiffrés

Les résultats numériques du cas MDG sont repris du document fourni. La base de transactions n'étant pas jointe à cette révision, ils n'ont pas été recalculés. L'unité monétaire, la période, les seuils de satisfaction et les conventions de calcul doivent être précisés dans le rapport d'application.

Avant-propos

L'analyse de données ne commence pas par un graphique complexe, un test statistique ou un modèle prédictif. Elle commence par une compréhension rigoureuse de chaque variable. Une variable mal comprise produit des indicateurs mal choisis, des graphiques trompeurs et, au final, de mauvaises décisions.

L'analyse univariée constitue donc la première étape statistique structurée d'un projet Data Analyst. Elle répond à une question simple en apparence : « Que nous apprend cette variable, prise séparément ? » Cette question permet de décrire la structure d'une base, de repérer les anomalies, d'identifier les valeurs typiques et atypiques, et de préparer des analyses plus avancées.

Fil conducteur pédagogique Dans toute la note, on applique la chaîne suivante : Souci du décideur → Question métier → Variable → Type de variable → Contrôle qualité → Indicateurs → Graphique → Résultat → Interprétation → Insight → Décision.

Objectifs pédagogiques

- Définir correctement l'analyse univariée et la distinguer des analyses bivariée et multivariée.
- Identifier le type statistique d'une variable avant de choisir une méthode.
- Calculer et interpréter les fréquences, pourcentages, mesures de tendance centrale et mesures de dispersion.
- Lire correctement les quartiles et les valeurs atypiques.
- Choisir un graphique cohérent avec la nature de la variable.
- Transformer un résultat statistique en message métier compréhensible.
- Reconnaître les limites de l'analyse univariée et savoir quand passer à l'analyse bivariée.

Prérequis

Aucun prérequis avancé en statistique n'est exigé. L'apprenant doit toutefois être capable de manipuler une feuille Excel, d'identifier des colonnes, de filtrer des données et d'utiliser des fonctions simples.

1 Du souci du décideur à la question statistique

Le Data Analyst ne commence pas par choisir une formule. Il commence par comprendre le besoin du décideur. Dans le projet MDG, le Chef ne demande pas directement une moyenne ou un quartile ; il exprime un souci de gestion.

Souci du décideur « Avant de comparer les agences, les clients ou les produits, je veux savoir si notre base est fiable et ce que chaque variable nous apprend réellement sur notre activité. »

Le rôle du Data Analyst consiste à transformer ce souci en questions mesurables. Chaque question doit pouvoir être reliée à une ou plusieurs variables de la base.

Souci exprimé	Question métier	Variable	Type d'analyse
Je veux savoir qui sont nos clients.	Comment se répartissent les segments clients ?	segment	Univariée
Je veux connaître une vente typique.	Quel est le CA net typique d'une transaction ?	CA_net	Univariée
Je veux connaître les agences les plus performantes.	Quelle agence génère le plus de marge ?	agency_name + Marge	Bivariée
Je veux comprendre la satisfaction.	Quel est le niveau de satisfaction observé ?	satisfaction_score	Univariée
Je veux savoir si les délais affectent les clients.	Le délai est-il associé à la satisfaction ?	delai + satisfaction	Bivariée

Principe Une question est univariée lorsqu'elle peut être résolue en étudiant une seule variable. Dès que la question compare deux dimensions, on quitte l'univarié.

2 Définition et rôle de l'analyse univariée

L'analyse univariée est l'étude descriptive d'une seule variable à la fois. Elle cherche à résumer la distribution de cette variable, à identifier son niveau central, sa dispersion, ses catégories dominantes, ses valeurs extrêmes et, lorsque cela est pertinent, ses valeurs atypiques.

2.1 Ce que l'analyse univariée cherche à répondre

Question statistique	Indicateur possible	Exemple MDG
Combien ?	Effectif / fréquence	Nombre de transactions par segment
Quelle proportion ?	Pourcentage	Part de WhatsApp dans les canaux
Quelle valeur typique ?	Médiane / moyenne	CA net typique
Quelle catégorie domine ?	Mode	Segment le plus fréquent
Les valeurs sont-elles dispersées ?	Écart-type / IQR	Dispersion du CA net
Existe-t-il des extrêmes ?	Min / Max / outliers	Grosses transactions

2.2 Pourquoi elle est indispensable

- Elle donne une première photographie de la base.
- Elle permet de repérer des erreurs ou des valeurs surprenantes.
- Elle aide à choisir entre moyenne, médiane, quartiles et autres indicateurs.
- Elle permet de construire des graphiques pertinents.
- Elle évite de lancer des analyses complexes sur des variables mal comprises.
- Elle fournit au management des réponses descriptives directement exploitables.

3 Quand utiliser l'analyse univariée ?

Moment du projet	Utilité	Exemple dans MDG
Après la préparation des données	Décrire les données propres	Distribution du CA_net
Avant une comparaison entre groupes	Comprendre chaque variable séparément	Agence seule avant Agence × Marge
Avant un test statistique	Examiner dispersion et extrêmes	CA_net avant comparaison de moyennes
Avant un modèle	Comprendre les échelles et distributions	Prix, quantité, marge
Dans un reporting descriptif	Fournir une photographie claire	Transactions par mois
Lors d'un contrôle qualité	Repérer anomalies et valeurs impossibles	Remises, quantités, prix

Règle pratique Si la question est : « Que nous dit cette variable prise séparément ? », commencez par une analyse univariée.

4 Identifier le type de variable

Définir l'unité d'observation

Dans une base de transactions, une ligne représente une transaction. Les effectifs par segment mesurent donc des transactions, sauf dédoublement explicite des clients. Une date est un repère temporel ; un identifiant est un rôle de colonne et non une échelle statistique. Un prix ou un montant est une mesure numérique, souvent enregistrée avec une précision finie.

Le type de variable détermine les calculs et les graphiques qui ont du sens. Une erreur fréquente consiste à appliquer la même méthode à toutes les colonnes.

Type	Définition	Exemples MDG	Outils adaptés
Qualitative nominale	Catégories sans ordre naturel	segment, category, canal_vente, sexe	Effectifs, %, mode, barres
Qualitative ordinale	Catégories ordonnées	Niveau_satisfaction, Classe_delai	Effectifs, %, barres ordonnées
Quantitative discrète	Comptage en nombres entiers	quantity	Moyenne, médiane, quartiles, histogramme
Quantitative de mesure	Mesure numérique	CA_net, Marge, unit_price	Centre, dispersion, histogramme, boxplot
Date / période	Temps ou période	date, Mois, Trimestre	Fréquences, courbe
Identifiant	Code de repérage	transaction_id, client_id	Unicité, doublons, nombre distinct

Attention Un identifiant n'est pas une variable sur laquelle on calcule une moyenne. Pour `transaction_id` ou `client_id`, on vérifie plutôt l'unicité, les doublons et le nombre de valeurs distinctes.

5 Analyser une variable qualitative

Pour une variable qualitative, l'objectif est de décrire la répartition des observations entre différentes catégories.

5.1 Indicateurs essentiels

Indicateur	Définition	Question à laquelle il répond
Effectif	Nombre d'observations d'une catégorie	Combien ?
Pourcentage	Part d'une catégorie dans le total	Quelle proportion ?
Mode	Catégorie la plus fréquente	Quelle catégorie domine ?
Manquants	Nombre de cellules vides	La variable est-elle complète ?

$$p_j = 100 \frac{n_j}{n_{\text{valides}}}.$$

Calculer les pourcentages sur les observations valides, puis présenter séparément les valeurs manquantes. Si le dénominateur inclut toutes les lignes, le préciser. Un zéro observé ne doit pas être assimilé à une valeur manquante.

5.2 Exemple MDG : segment client

Segment	Transactions	Part
Grande entreprise	228	22,8 %
Institution	215	21,5 %
PME	194	19,4 %
ONG	187	18,7 %
Indépendant	176	17,6 %

Lecture : « Grande entreprise » est le segment le plus fréquent, avec 22,8 % des transactions. Cependant, l'écart avec les autres catégories reste modéré. La répartition des transactions entre segments est relativement équilibrée. Elle ne décrit pas directement la répartition des clients uniques : un même client peut avoir plusieurs transactions.

Interprétation métier Être le segment le plus fréquent ne signifie pas être le segment le plus rentable. Pour répondre à la rentabilité par segment, il faudra croiser segment avec CA_net ou Marge.

6 Analyser une variable quantitative

Une variable quantitative contient des valeurs numériques auxquelles les opérations arithmétiques ont un sens. L'analyse univariée cherche alors à décrire le centre, la position, la dispersion et les extrêmes.

6.1 Familles d'indicateurs

Famille	Indicateurs	Objectif
Tendance centrale	Moyenne, médiane, mode	Décrire une valeur typique
Position	Q1, médiane, Q3	Situer les observations dans la distribution
Dispersion	Étendue, écart-type, IQR	Mesurer l'hétérogénéité
Extrêmes	Minimum, maximum	Identifier les bornes observées
Valeurs atypiques	Règle de l'IQR	Repérer des observations inhabituelles

7 Moyenne, médiane et mode : choisir le bon centre

7.1 La moyenne

La moyenne additionne toutes les valeurs puis divise cette somme par le nombre d'observations. Elle utilise toute l'information disponible, mais elle est sensible aux valeurs très élevées ou très faibles.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

7.2 La médiane

La médiane est la valeur qui coupe la série ordonnée en deux parties égales. 50 % des observations sont inférieures ou égales à la médiane et 50 % sont supérieures ou égales.

7.3 Le mode

Le mode est la valeur ou la catégorie la plus fréquente. Il est particulièrement utile pour les variables qualitatives.

7.4 Exemple décisif : CA net chez MDG

Indicateur	Résultat	Lecture
Médiane	361	Une transaction centrale vaut environ 361
Moyenne	697,14	La moyenne est nettement plus élevée
Maximum	15 600	Quelques ventes très importantes existent

Pourquoi la médiane est importante ici ? La moyenne est presque deux fois supérieure à la médiane. Cet écart est compatible avec une distribution asymétrique à droite ; l'histogramme permet de compléter le diagnostic. Pour décrire la transaction typique, la médiane est plus représentative.

8 Quartiles et lecture de la position des données

Convention de calcul des quartiles

Avec une série finie, des valeurs répétées et une interpolation, les proportions situées sous les quartiles ne sont pas toujours exactement égales à 25 ou 75 %. Indiquer la convention utilisée ; dans Excel, employer de façon cohérente `QUARTILE.INCLUDE` ou `QUARTILE.EXCLUDE`.

Les quartiles divisent une série ordonnée en quatre parties contenant chacune environ 25 % des observations. Ils permettent de comprendre la position des données sans être fortement influencés par quelques valeurs extrêmes.

Indicateur	Position	Interprétation
Q1	25e percentile	Environ 25 % des observations se situent au niveau de Q1 ou en dessous
Q2	50e percentile	Q2 correspond à la médiane
Q3	75e percentile	Environ 75 % des observations se situent au niveau de Q3 ou en dessous

8.1 Exemple : CA net

Quartile	Valeur	Lecture métier
Q1	143,53	Environ 25 % des transactions ont un CA net $\leq 143,53$
Médiane	361	50 % des transactions ont un CA net ≤ 361
Q3	780	Environ 75 % des transactions ont un CA net ≤ 780

Lecture utile au décideur Dire « $Q3 = 780$ » n'est pas une interprétation. L'interprétation est : « Environ 75 % des transactions de MDG ont un CA net inférieur ou égal à 780 ; environ 25 % dépassent ce niveau. »

9 Dispersion : étendue, écart-type et IQR

Deux séries peuvent avoir la même moyenne tout en étant très différentes. La dispersion mesure à quel point les observations sont regroupées ou éloignées autour du centre.

Indicateur	Calcul / idée	Lecture
Étendue	Maximum - Minimum	Amplitude totale de la série
Écart-type	Dispersion autour de la moyenne	Grand écart-type = forte hétérogénéité
IQR	$Q3 - Q1$	Dispersion de la moitié centrale des observations

9.1 Exemple : CA net

Chez MDG, l'écart-type du CA net est d'environ 1 208,27 alors que la moyenne est de 697,14. Cette situation indique une très forte dispersion : les transactions n'ont pas toutes la même taille et quelques grosses ventes se détachent fortement.

L'écart-type s'exprime dans la même unité que le CA net. Pour décrire une population complète, le dénominateur est n ; pour estimer la variance d'une population à partir d'un échantillon, on emploie $n - 1$:

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

Préciser le périmètre et la convention. Une dispersion élevée ne signifie pas, en elle-même, que les données sont erronées.

10 Valeurs atypiques : détecter sans supprimer aveuglément

Une valeur atypique, ou outlier, est une observation éloignée du cœur de la distribution. Elle peut provenir d'une erreur de saisie, mais elle peut aussi être une observation parfaitement réelle.

$$IQR = Q_3 - Q_1.$$

$$B_{\text{haute}} = Q_3 + 1,5 IQR.$$

$$B_{\text{basse}} = Q_1 - 1,5 IQR.$$

Variable	Borne haute	Outliers hauts	Lecture
Quantité	8,5	63	Commandes de 9 unités ou plus
Prix unitaire	507,5	125	Produits très chers / premium
CA net	1 734,71	78	Grosses transactions
Marge	517,65	90	Transactions à forte contribution

Règle professionnelle Outlier statistique $\neq$ erreur. Avant toute suppression : vérifier la saisie, vérifier la cohérence métier, rechercher la source et documenter la décision.

11 Choisir et interpréter les graphiques

Un graphique est un outil d'analyse et de communication. Il doit être choisi en fonction de la variable et de la question posée.

Objectif	Graphique recommandé	Exemple MDG
Comparer des catégories	Barres	Transactions par segment
Montrer une composition avec peu de catégories	Secteur	Modes de paiement
Observer une distribution numérique	Histogramme	CA net
Voir quartiles et outliers	Boîte à moustaches	Marge
Observer une évolution temporelle	Courbe	Transactions par mois

11.1 Comment interpréter un graphique

1. Commencer par rappeler ce qui est représenté : variable, unité et population.
2. Identifier la tendance principale : catégorie dominante, concentration, stabilité ou dispersion.
3. Comparer les écarts observés sans qualifier de « significative » une différence qui n'a pas fait l'objet d'un test statistique.
4. Éviter de tirer des conclusions causales à partir d'un simple graphique descriptif.
5. Terminer par une implication métier ou une question à approfondir.

12 Applications détaillées au cas MDG

12.1 Quantité par transaction

Indicateur	Résultat	Interprétation
Minimum	1	Toute transaction contient au moins une unité
Q1	1	Environ 25 % des transactions portent sur une unité
Médiane	2	La transaction centrale porte sur 2 unités
Moyenne	3,23	Les grosses commandes élèvent la moyenne
Q3	4	Environ 75 % des transactions portent sur 4 unités ou moins
Maximum	20	Certaines commandes sont exceptionnellement volumineuses

12.2 Satisfaction

Indicateur	Résultat	Lecture
Moyenne	6,09 / 10	Score moyen observé ; à comparer à un objectif défini
Médiane	6,1 / 10	Très proche de la moyenne
Faible	30,8 %	Près d'un tiers des observations
Très bonne	1,8 %	Niveau exceptionnellement rare

Le score moyen est de 6,09/10 et la catégorie « Très bonne » représente 1,8 % des observations. Le jugement porté sur ce niveau doit se référer à un objectif de service et à des seuils de classement explicitement définis. L'analyse univariée permet d'identifier le problème, mais pas encore d'en expliquer la cause.

12.3 Activité mensuelle

Le volume mensuel varie de 79 transactions en janvier à 89 en juin. L'écart est relativement faible, ce qui suggère une activité assez régulière en nombre de transactions. Il serait toutefois incorrect de conclure que le chiffre d'affaires est stable sans analyser le CA par mois.

13 Rentabilité : ce que l'univarié permet de dire

Vocabulaire financier à respecter

Le **taux de marque** rapporte la marge au chiffre d'affaires net. Le **taux de marge** rapporte la marge au coût d'achat ou de revient retenu. Le champ historique **Taux_marge**, s'il contient marge/CA net, doit être renommé ou accompagné d'une définition explicite. Ces ratios décrivent la contribution commerciale ; ils ne mesurent pas, à eux seuls, la rentabilité nette.

Dans le cas MDG, la rentabilité commerciale est approchée par la marge et le taux de marque. Ces indicateurs ne doivent pas être confondus avec le bénéfice net de l'entreprise.

Marge = CA net - Coût total

Taux de marque = (Marge / CA net) × 100

Indicateur	Résultat MDG	Interprétation
Marge totale	214 221,98	Marge commerciale cumulée des transactions
Marge moyenne	214,22	Moyenne influencée par de grosses transactions
Marge médiane	100,80	Valeur plus représentative d'une transaction centrale
Taux de marque moyen	28,29 %	Moyenne non pondérée des ratios individuels ; distincte du ratio global

Limite La marge commerciale ne tient pas nécessairement compte des salaires, loyers, transport, énergie, administration et autres charges générales. Elle ne doit donc pas être appelée « bénéfice net ».

13.1 Une subtilité importante

Pour comparer la rentabilité d'une agence, d'un produit ou d'un segment, l'analyse devient bivariee : on croise une variable catégorielle avec Marge ou Taux_marque.

Taux de marque du groupe = (Somme des marges du groupe / Somme des CA nets du groupe) × 100

Cette formule est préférable à la simple moyenne des taux individuels lorsque les transactions ont des tailles très différentes.

Le ratio global est une moyenne des taux individuels pondérée par les CA nets, lorsque ceux-ci sont strictement positifs. Un CA net nul rend le ratio individuel indéfini ; les retours, annulations et CA négatifs exigent une règle métier explicite. La moyenne de 28,29 % ne doit donc pas être présentée comme le taux de marque global.

14 Du résultat à la décision

Un Data Analyst ne s'arrête pas au calcul. Il transforme le résultat en information utile, tout en respectant ce que les données permettent réellement de conclure.

Question du décideur	Résultat	Interprétation	Décision prudente
Quel segment domine ?	Grande entreprise : 22,8 %	Domination légère	Ne pas cibler exclusivement ce segment
Quelle vente est typique ?	CA médian : 361	Moyenne tirée par de grosses ventes	Piloter avec médiane + moyenne
Sommes-nous satisfaits ?	Satisfaction moyenne : 6,09/10	Niveau à apprécier selon un objectif explicite	Chercher les facteurs explicatifs
Les délais sont-ils maîtrisés ?	33,4 % classés longs	Un tiers mérite attention	Analyser Délai × Satisfaction
L'activité est-elle saisonnière ?	79 à 89 transactions/mois	Volume assez stable	Analyser ensuite le CA mensuel

Méthode de formulation Un bon commentaire statistique comporte trois niveaux : (1) le résultat chiffré, (2) sa signification statistique, (3) son implication métier.

15 Limites et transition vers l'analyse bivariée

L'analyse univariée décrit. Elle ne démontre pas une relation entre deux variables et encore moins une causalité.

- Une agence fréquente n'est pas nécessairement l'agence la plus rentable.
- Un produit souvent vendu n'est pas nécessairement celui qui génère le plus de marge.
- Une satisfaction moyenne faible ne permet pas d'affirmer que le délai en est la cause.
- Une remise élevée ne permet pas, à elle seule, de conclure qu'elle augmente ou réduit le CA.
- Une catégorie dominante en fréquence n'est pas automatiquement prioritaire pour l'investissement.

15.1 Questions qui appellent maintenant une analyse bivariée

Constat univarié	Question suivante
Certaines agences sont plus actives	Agence $\times$ CA / Marge
Les délais longs représentent environ un tiers	Délai $\times$ Satisfaction
Informatique domine le volume	Catégorie $\times$ Marge
Les segments sont relativement équilibrés	Segment $\times$ CA net
Les remises varient de 0 à 10 %	Remise $\times$ CA / Marge

16 Fiche méthode et exercices d'application

16.1 Fiche méthode à retenir

Étape	Question à se poser
1. Contexte	Quel est le problème ou le souci du décideur ?
2. Question métier	Quelle question précise faut-il résoudre ?
3. Variable	Quelle colonne contient l'information nécessaire ?
4. Type	Qualitative, quantitative, temporelle ou identifiant ?
5. Qualité	La variable contient-elle des manquants ou anomalies ?
6. Indicateurs	Quelles statistiques ont du sens ?
7. Graphique	Quel visuel répond le mieux à la question ?
8. Interprétation	Que signifie réellement le résultat ?
9. Insight	Qu'est-ce que le Chef doit retenir ?
10. Suite	Faut-il une analyse bivariée ?

16.2 Exercices d'application

1. À partir de la variable `payment_method`, produisez un tableau de fréquences et rédigez trois phrases d'interprétation.
2. Pour la variable `unit_price`, calculez minimum, Q1, médiane, moyenne, Q3, maximum et écart-type. Comparez moyenne et médiane.
3. Expliquez en langage métier ce que signifie $Q3 = 780$ pour le CA net.
4. Expliquez pourquoi la présence de 78 outliers de CA net ne justifie pas leur suppression automatique.
5. À partir de la satisfaction moyenne de 6,09/10, formulez deux questions bivariées qui permettraient d'approfondir le diagnostic.
6. Expliquez pourquoi le classement des agences par nombre de transactions ne suffit pas pour parler de rentabilité.

16.3 Questions de révision

N°	Question
1	Qu'est-ce qu'une analyse univariée ?
2	Quelle différence entre moyenne et médiane ?
3	Que signifie Q1 ? Q3 ?
4	Pourquoi calcule-t-on l'écart-type ?
5	Qu'est-ce qu'un outlier ?
6	Quel graphique choisir pour une variable qualitative ?
7	Pourquoi le CA moyen peut-il être trompeur ?
8	À quel moment passe-t-on de l'univarié au bivarié ?

À retenir L'analyse univariée ne consiste pas à empiler des statistiques. Elle consiste à choisir les bons indicateurs pour une variable donnée, à les interpréter correctement et à relier le résultat à une question métier.

Glossaire essentiel

Terme	Définition
Variable	Caractéristique observée pour chaque ligne de la base.
Effectif	Nombre d'observations correspondant à une valeur ou catégorie.
Fréquence	Part relative d'une catégorie ou d'une valeur.
Moyenne	Somme des valeurs divisée par leur nombre.
Médiane	Valeur qui partage la série ordonnée en deux moitiés.
Mode	Valeur ou catégorie la plus fréquente.
Quartile	Valeur qui délimite 25 %, 50 % ou 75 % de la série ordonnée.
Écart-type	Mesure de la dispersion autour de la moyenne.
IQR	Écart interquartile, égal à Q3 - Q1.
Outlier	Observation atypique par rapport au cœur de la distribution.
Insight	Conclusion utile à la décision issue de l'analyse.
Analyse bivariable	Étude de la relation ou de la comparaison entre deux variables.

Conclusion générale

L'analyse univariée constitue le socle de toute analyse statistique sérieuse. Dans le projet MDG, elle permet de comprendre le portefeuille client, le mix produit, la structure des transactions, les niveaux de CA et de marge, la satisfaction, les délais et les valeurs atypiques. Elle permet surtout d'apprendre une discipline essentielle : ne jamais interpréter un chiffre sans le replacer dans sa distribution, son contexte métier et ses limites.

Une fois cette étape maîtrisée, l'apprenant est prêt à répondre à des questions plus riches : quelles agences génèrent le plus de marge ? quels segments achètent le plus ? les délais affectent-ils la satisfaction ? Ces questions ouvrent naturellement la voie à l'analyse bivariable.

Annexe pratique : mise en œuvre sous Excel

Un protocole reproductible

Conserver la base brute, travailler sur une copie et documenter les filtres appliqués. Vérifier la granularité des lignes, les doublons, les types, les valeurs manquantes et les unités. Pour chaque variable, présenter l'effectif valide et l'effectif manquant avant les indicateurs.

Exemples de fonctions : Excel en français

Pour une plage numérique nommée valeurs : NB(valeurs), MOYENNE(valeurs), MEDIANE(valeurs), MIN(valeurs), MAX(valeurs), QUARTILE.INCLUDE(valeurs;1) et QUARTILE.INCLUDE(valeurs;3). Pour l'écart-type, choisir ECARTYPE.STANDARD(valeurs) pour l'estimation sur échantillon ou ECARTYPE.PEARSON(valeurs) pour la population décrite. Les noms dépendent de la langue et de la version d'Excel.

Pour une variable qualitative, créer un tableau croisé dynamique : catégories en lignes et comptage

d'un identifiant de transaction non vide en valeurs. Contrôler les catégories vides ; calculer la part de chaque catégorie sur le dénominateur annoncé. Un comptage d'identifiants ne constitue pas un comptage de clients uniques.

Contrôle des valeurs atypiques

Calculer les quartiles sur les données valides, puis les deux bornes. Signaler les observations strictement inférieures à la borne basse ou strictement supérieures à la borne haute. Conserver un journal des vérifications et des corrections. Dans une boîte à moustaches de Tukey, les moustaches atteignent les valeurs observées les plus extrêmes restant dans les bornes ; elles ne correspondent pas nécessairement au minimum et au maximum.

Lecture temporelle

Le décompte des transactions par mois décrit la distribution d'une période dérivée de la date. Une courbe reliant un indicateur au temps est une présentation chronologique, à distinguer de la simple distribution univariée. Pour comparer des volumes mensuels, vérifier les mois incomplets, les jours d'ouverture et la couverture de la période. Une saisonnalité exige des cycles répétés ; quelques écarts mensuels ne suffisent pas à l'établir.

Gabarit d'un commentaire professionnel

Résultat, portée et suite

« Sur les transactions valides du périmètre étudié, le CA net médian est de 361 unités monétaires, contre une moyenne de 697,14. Cet écart indique que la moyenne décrit une autre dimension que la transaction centrale et invite à examiner la queue supérieure de la distribution. Nous recommandons de suivre conjointement la médiane, la moyenne et les quartiles, puis de comparer la contribution des segments à la marge. »

Contrôles avant remise

- Chaque tableau indique la variable, l'unité, la période et le dénominateur.
- Les modalités ordinales gardent leur ordre ; les graphiques n'emploient pas d'effets 3D.
- Les seuils « faible », « très bonne » ou « long » sont définis dans le dictionnaire.
- Les arrondis sont cohérents et les totaux sont vérifiés.
- Les résultats descriptifs, les hypothèses explicatives et les décisions proposées sont clairement distingués.